AWS 黑客松：詐騙偵測挑戰賽資料集說明文件

1. 簡介

本文件旨在提供參賽者關於三個特定詐騙資料集的詳細資訊。這些數據涵蓋了目前台灣及亞洲地區最常見的詐騙媒介：**簡訊 (SMS)**、**惡意連結 (URL)** 以及 **社群媒體廣告 (Social Media Ads)**。參賽者可利用這些數據進行機器學習模型的訓練、威脅情資分析或開發自動化辨識系統。

2. 資料集詳細說明

A. 詐騙簡訊資料集 (Scam SMS dataset.csv)

- **數據量**：100 筆樣本。
- **欄位說明**：SMS text（簡訊原始文字）。
- **資料內容說明**： 此資料集主要反映了台灣常見的電信詐騙型態。其中以「非法貸款」為大宗，內容常包含「免聯徵、不照會、快速撥款」等誘人字眼，並附上 Line ID 或縮網址（如 maac.io, lihi.cc）引導受害者聯繫。另一類常見內容為「帳號異常通知」，假冒 WhatsApp、YouTube 或銀行發送緊急警告，聲稱用戶帳號涉嫌違規或將被停權，藉此強迫用戶點擊釣魚連結進行身分驗證，進而竊取個資或通訊軟體控制權。

B. 詐騙連結資料集 (Scam URL dataset.csv)

- **數據量**：100 筆樣本。
- **欄位說明**：URL（惡意網址）。
- **資料內容說明**： 本資料集收集了大量具有威脅性的網址。內容特徵顯示，許多 URL 試圖透過「視覺相似法」偽裝成官方網站，例如針對中國信託 (CTBC)、玉山銀行 (ESUN) 或

財政部電子發票平台製作的假入口頁面。此外，這些連結大量使用廉價或不常見的頂級域名（TLD），如 .top, .sbs, .xyz，或利用短網址服務（如 0ab.cn, j5z.cn）來隱藏最終的惡意目的地，藉此規避系統的初步安全過濾。

C. 社群媒體詐騙資料集 (Social Media Scam Dataset.csv)

- **數據量**：100 筆樣本。
- **欄位說明**：facebook_ad_link（廣告庫連結）、content（廣告內文）。
- **資料內容說明**： 此資料集聚焦於社群平台的廣告詐騙，內容大致分為「一頁式購物詐騙」與「投資贈書詐騙」。前者通常以極低價格促銷民生用品（如理髮剪、收納袋）來吸引消費者；後者則高度針對投資族群，假借財經名人（如黃董、蘇姿丰）的名義，宣稱免費贈送 AI 應用書籍或提供高額 USDT 模擬金，誘導用戶加入不法投資群組。這類廣告文案通常文字量較大，且帶有強烈的情緒煽動與限時限量的迫切感。

---

3. 安全與隱私注意事項

1. **連結安全性**：資料集中包含真實的惡意網址與縮網址。**請勿直接在日常使用的瀏覽器中點擊這些連結**。建議在受控的沙箱環境（Sandbox）或利用程式化的方式進行靜態分析。
2. **資料去識別化**：雖然資料集中包含部分電話號碼與 Line ID，但主要用於開發測試。請參賽者在展示解決方案或輸出結果時，務必遵循資安準則，對涉及個資的部分進行適當遮蔽（Masking）。
3. **合法合規**：此資料集僅供黑客松競賽期間開發使用，請勿將其用於任何非法用途或未經授權的測試。

祝各位參賽者開發順利，透過 AWS 的強大算力與創新技術，為打擊詐騙貢獻心力！